

Detekcja i charakterystyka zmian miażdżycowych naczyń wieńcowych z użyciem uczenia maszynowego

Bartosz Gacek
Barbara Wojtarowicz

17.06.2025

1. Wprowadzenie

Celem projektu było zastosowanie technik uczenia maszynowego do wspomagania diagnostyki choroby wieńcowej poprzez automatyczną detekcję i charakterystykę zmian miażdżycowych na obrazach medycznych naczyń wieńcowych.

Zespół otrzymał dwa główne komponenty zbioru danych:

- Obrazy medyczne przedstawiające naczynia wieńcowe,
- Plik CSV zawierający współrzędne zmian (bounding boxy) oraz ich charakterystykę (np. zwężenie, typ zmiany).


Dane te miały posłużyć do przeprowadzenia dwóch głównych zadań:

1. Detekcji zmian miażdżycowych na obrazach,
2. Klasyfikacji cech wykrytych zmian na podstawie ich wycinków obrazowych.

2. Detekcja zmian miażdżycowych

Opis zadania

Pierwszym krokiem było wytrenowanie modelu detekcyjnego, który na podstawie obrazu lokalizowałby zmiany miażdżycowe w postaci bounding boxów. Model miał zwracać współrzędne tych ramek oraz prawdopodobieństwo detekcji.




Rysunek 1: Przykładowe obrazy medyczne z pierwotnego zbioru danych.

Wstępne podejście — YOLO

W pierwszej iteracji zdecydowano się na wykorzystanie rodziny modeli **YOLO (You Only Look Once)** — nowoczesnych i wydajnych detektorów obiektów, szczególnie skutecznych w analizie obrazów w czasie rzeczywistym.

Zastosowano modele YOLOv8 i YOLOv11 w wariantach **nano**, **medium** oraz **large**, zakładając, że gotowe, pretrenowane sieci powinny być w stanie wyekstrahować cechy nawet przy ograniczonej liczbie danych.




Rysunek 2: Nieudane predykcje: błędne lokalizacje i niskie confidence scores.

Pomimo licznych prób, model nie był w stanie nauczyć się poprawnej detekcji. Wyniki były losowe, a przewidywania prawie nigdy nie pokrywały się z rzeczywistymi zmianami.

Analiza etykiet

Kolejnym krokiem była dogłębna analiza jakości etykiet w zbiorze. Stworzono narzędzie wizualizujące etykiety na obrazach, co pozwoliło zauważyć istotne problemy:


- wiele ramek obejmowało tło lub obszary bez widocznych struktur naczyniowych,
- część ramek miała rozmiar rzędu kilku pikseli, co uniemożliwiało efektywne uczenie,
- niektóre etykiety były rozmieszczone losowo, bez żadnego powiązania z widocznymi zmianami.



Rysunek 3: Ręczna analiza etykiet i selekcja poprawnych ramek.

Ręczne czyszczenie danych

Zaprojektowano interfejs umożliwiający szybkie przeglądanie obrazów z nałożonymi etykietami oraz identyfikatorami zmian. Na tej podstawie ręcznie usunięto większość błędnych ramek.




Rysunek 4: Przykłady błędnych oznaczeń zmian w zbiorze danych.

Dalsze optymalizacje

Po oczyszczeniu zbioru rozpoczęto kolejne eksperymenty z modelami. Poprawa była zauważalna, ale wyniki nadal nie były zadowalające. Po dokładnym zbadaniu wyników okazało się, że YOLO automatycznie stosuje intensywne augmentacje danych: *mosaic*, *shear*, *perspective* — które w przypadku obrazów medycznych zakłócały oryginalną strukturę.

Po wyłączeniu tych augmentacji (lub ograniczeniu ich siły) wyniki poprawiły się istotnie.



Rysunek 5: Zadowalające predykcje po oczyszczeniu danych i ograniczeniu augmentacji.

Wnioski

Ostatecznie, mimo że metryki jakości (np. mAP) nie były spektakularne, ręczna analiza predykcji wykazała, że model poprawnie wykrywa wiele zmian miażdżycowych. Jakość detekcji była w dużym stopniu uzależniona od jakości etykiet i zgodności wizualnej.

3. Charakterystyka zmian

Cel

Drugim zadaniem była klasyfikacja charakterystyki zmian, takich jak:

- typ zmiany (np. zwężenie, blaszka miażdżycowa),
- stopień zwężenia naczynia,
- czas trwania niedrożności.

Problemy z wejściem do klasyfikatora

Zmiennej wielkości bounding boxy stanowiły przeszkodę dla trenowania klasyfikatora obrazów. Zdecydowano się na podejście ujednolicające: wyznaczano środek boxa, a następnie wycinano kwadratowy obszar 100x100 pikseli wokół niego.




Rysunek 6: Wycinki 100x100 px używane do klasyfikacji.

Model klasyfikacyjny

Wybrano model **CatBoostClassifier** — gradientowy model drzew decyzyjnych, który cechuje się wysoką wydajnością i odpornością na nadmierne dopasowanie przy małych i zróżnicowanych zbiorach danych.

Model został wytrenowany osobno dla każdej cechy, co pozwoliło dostosować hiperparametry do konkretnego podzadania.



Rysunek 7: Wyniki klasyfikatora cech zmian miażdżycowych.

Wyniki były zadowalające — model poprawnie klasyfikował większość przypadków, a błędy były głównie związane z niejednoznacznymi przykładami lub artefaktami w obrazach.

4. Podsumowanie i wnioski

- Wysoka jakość etykiet jest kluczowa dla powodzenia projektów detekcyjnych.
- Modele YOLO mogą być skuteczne w analizie obrazów medycznych, ale wymagają dostosowania augmentacji i rozmiaru wejścia.
- Klasyfikacja cech zmian oparta na wyciętych fragmentach obrazów sprawdziła się bardzo dobrze — CatBoost okazał się trafnym wyborem.
- Projekt ukazuje istotność iteracyjnego podejścia: analizy błędów, czyszczenia danych i testowania alternatywnych architektur.